# Bl 코딩실무

한주현

200523

Bioinformatics Engineer at 3billion

Interdisciplinary Program in Medical Informatics at Seoul National University

# 강사소개

강사 소개					
이름	한주현				
소속	3billion, Bioinformatics Engineer Seoul National University, Medical Informatics				
메일	kenneth,jh.han@snu.ac.kr				
주요 업무	Human Genome Analysis (WGS, WES) Rare Disease Analysis Bioinformatics Algorithms Analysis Pipeline / Platform Development Full Stack Development Cloud Computing				
주 언어	Python, JAVA, JavaScript, Bash shell				
저서	니콜라스 볼커 이야기 (2016.10, 금창원 외 공역) 바이오파이썬으로 시작하는 생물정보학 (2019.03, 한주현)				
웹 페이지	https://korbillgates.tistory.com (블로그)				

강의 내용 또는 생물정보학, 취업 및 진로에 관련하여 궁금한점이 있으시면 언제든 메일로 문의해주세요

#### 강의 내용

- DNA Sequencing 데이터의 분석 방법 학습
- LINUX 환경에서 생물정보 툴 설치
- 파이썬 프로그래밍으로 생물정보 파일들 파싱하기
- LINUX를 활용한 Bioinformatics Pipeline 제작 학습

#### 목표 (과제)

- 1) 제공한 FASTQ 파일의 염기서열 개수를 세어본다.
- 2) 리눅스 환경에서 생물정보학 tool(samtools)을 설치하여 실행해보기.
- 3) 제공한 BAM 파일의 특정 영역 (chr10:42385150)을 samtools tview로 시각화하여 스크린샷한다.
- 4) 제공한 VCF 파일의 SNP와 Insertion, Deleletion 개수를 세어본다.

#### 준비물

- Linux 환경 (ubuntu 18.04 를 추천)
- Python3

참고 페이지

https://kennethjhan.github.io/Genome-Analysis-Tutorial/

#### 다음 파일들을 다운로드 해두세요

#### **FASTQ**

https://github.com/KennethJHan/Bioinformatics Programming 101/raw/master/GATK BestPractice/SRR000982 1.filt.fastq.gz

https://github.com/KennethJHan/Bioinformatics\_Programming\_101/raw/master/GATK\_BestPractice/SRR000982\_2.filt.fastq.gz

#### BAM

https://github.com/KennethJHan/Bioinformatics\_Programming\_101/raw/master/GATK\_BestPractice/SRR000982,mapped.sorted.markdup.bam https://github.com/KennethJHan/Bioinformatics\_Programming\_101/raw/master/GATK\_BestPractice/SRR000982,mapped.sorted,markdup,bam,bai

#### VCF

https://raw.githubusercontent.com/KennethJHan/Bioinformatics\_Programming\_101/master/GATK\_BestPractice/SRR000982.filtered.variants.annotat ed.vcf

# 리눅스에서 파일 다운로드 하는 방법

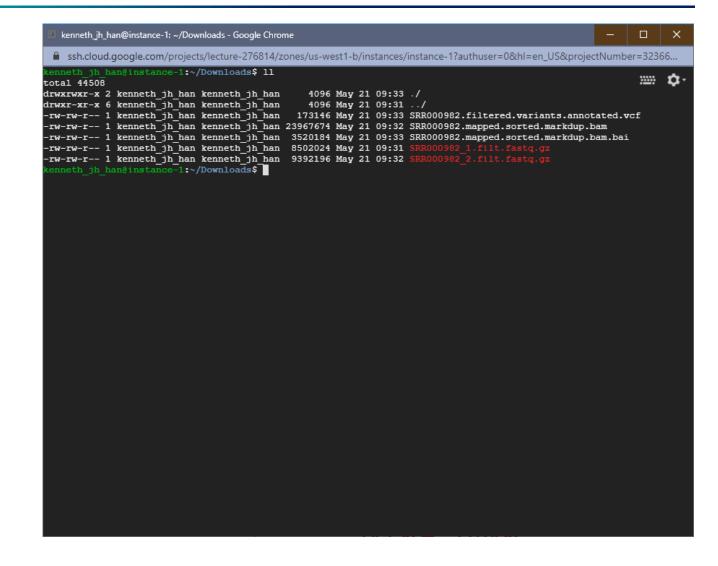
1) 적당한 장소에 다운받을 디렉토리를 mkdir 로 생성합니다

2) 파일 주소를 wget에 넣어 다운로드 받습니다.

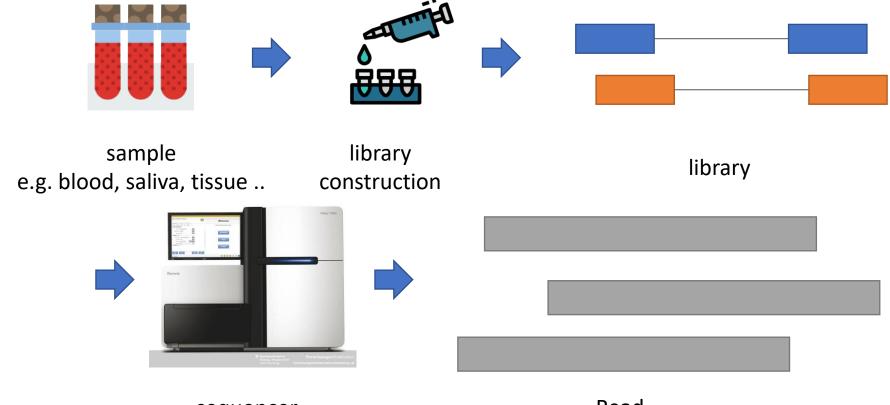
```
kenneth_jh_han@instance-1: ~/Downloads - Google Chrome
 ssh.cloud.google.com/projects/lecture-276814/zones/us-west1-b/instances/instance-1?authuser=0&hl=en_US&projectNumber=32366...
          han@instance-1:~$ mkdir Downloads
   neth jh han@instance-1:~$ cd Downloads
   neth jh han@instance-1:~/Downloads$ 11
drwxrwxr-x 2 kenneth jh han kenneth jh han 4096 May 21 09:27 ./
drwxr-xr-x 6 kenneth jh han kenneth jh han 4096 May 21 09:27 ../
    eth jh han@instance-1:~/Downloads$
   kenneth jh han@instance-1: ~/Downloads - Google Chrome
 ssh.cloud.google.com/projects/lecture-276814/zones/us-west1-b/instances/instance-1?authuser=0&hl=en_US&projectNumber=32366.
                       -1:~/Downloads$ wget https://github.com/KennethJHan/Bioinformatics_Programming_101/raw/maste
 GATK BestPractice/SRR000982 1.filt.fastq.gz
 -2020-05-21 09:31:48-- https://github.com/KennethJHan/Bioinformatics Programming 101/raw/master/GATK BestPractice
SRR000982 1.filt.fastq.gz
Resolving github.com (github.com)... 192.30.255.112
Connecting to github.com (github.com)|192.30.255.112|:443... connected.
HTTP request sent, awaiting response... 302 Found
Location: https://raw.githubusercontent.com/KennethJHan/Bioinformatics_Programming_101/master/GATK_BestPractice/SRR
000982 1.filt.fastq.gz [following]
 -2020-05-21 09:31:48-- https://raw.githubusercontent.com/KennethJHan/Bioinformatics Programming 101/master/GATK B
 stPractice/SRR000982 1.filt.fastq.gz
Resolving raw.githubusercontent.com (raw.githubusercontent.com)... 151.101.192.133, 151.101.128.133, 151.101.64.133
Connecting to raw.qithubusercontent.com (raw.qithubusercontent.com)|151.101.192.133|:443... connected.
HTTP request sent, awaiting response... 200 OK
Length: 8502024 (8.1M) [application/octet-stream]
Saving to: 'SRR000982 1.filt.fastq.gz'
2020-05-21 09:31:49 (35.8 MB/s) - `SRR000982_1.filt.fastq.gz' saved [8502024/8502024]
   neth jh han@instance-1:~/Downloads$ 11
total 8312
drwxrwxr-x 2 kenneth jh han kenneth jh han
                                            4096 May 21 09:31 ./
drwxr-xr-x 6 kenneth jh han kenneth jh han 4096 May 21 09:31 ../
-rw-rw-r-- 1 kenneth jh han kenneth jh han 8502024 May 21 09:31 SRR000982 1.filt.fastq.gz
    eth jh han@instance-1:~/Downloads$
```

# 리눅스에서 파일 다운로드 하는 방법

3) 모든 파일을 다 받으면 다음 그림과 같습니다. 파일의 개수와 사이즈를 체크해 보세요.



# Sequencing의 전반적 개요



sequencer

Read

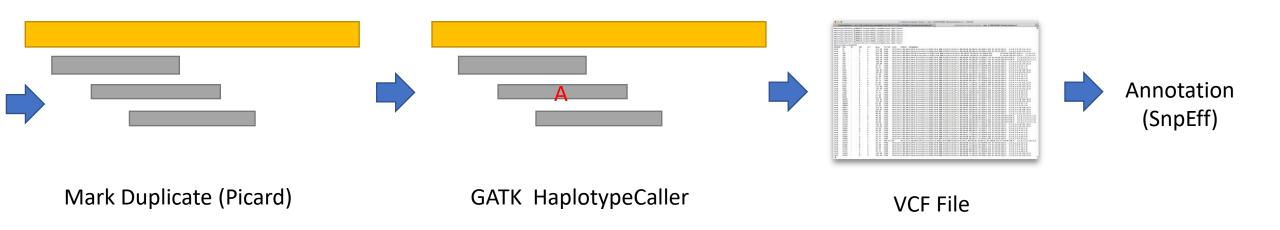
혈액, 타액, 조직 등과 같은 샘플에서 DNA를 추출하여 sequencer가 읽을 수 있도록 라이브러리를 제작하고 sequencing을 합니다. Sequencer가 라이브러리를 읽으면 read라고 하는 단위로 염기서열을 읽습니다. lllumina(일루미나) sequencing 장비의 경우 라이브러리를 앞뒤로 읽어서 read1, read2로 두 개의 read 파일을 생성합니다.

# Sequencing의 전반적 개요



읽어낸 read는 기준서열(reference sequence)와 비교하여 조각을 맞추는 align 작업을 하고, pcr 과정에서 생긴 duplicate을 picard와 같은 툴로 제거합니다.

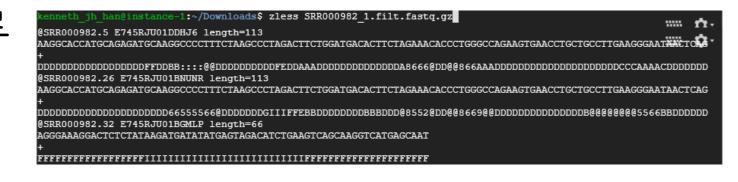
# Sequencing의 전반적 개요



그러고 난 뒤 기준 서열과 다른 염기를 찾아내는 과정인 variant calling 을 진행합니다. Variant call을 하게 되면 VCF (Variant Calling Format) 파일이 생성됩니다. VCF 파일은 테이블과 같은 구조로 생긴 텍스트 파일입니다. VCF 파일에는 변이의 위치와 기준서열, 변이서열 정보만 있어서 이 변이가 어떤 의미인지 붙이는 작업이 필요한데, 이름 annotation 이라고 합니다.

### FASTQ 파일 살펴보기

FASTQ 파일은 보통 gzip으로 압축된 형태이기에 눈으로 보려면 zless 명령어를 사용하여 봅니다.



FASTQ 파일은 네 줄이 하나의 read로 구성되어있습니다. 첫 번째 줄은 @로 시작하는 헤더 두 번째 줄은 엮기서열 세 번째 줄은 + 기호로 된 구분 줄 네 번째 줄은 염기서열에 대한 quality score 입니다.

### FASTQ 파일에서 염기 세기

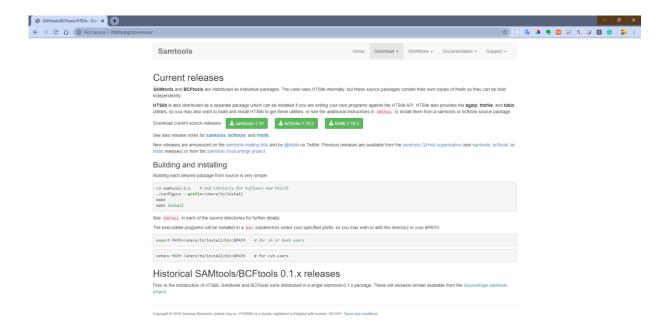
```
kenneth_jh_han@instance-1:~/Downloads$ python3 read_base.py SRR000982_1.filt.fastq.gz
3743235 2466934 2408976 3770887
kenneth_jh_han@instance-1:~/Downloads$ python3 read_base.py SRR000982_2.filt.fastq.gz
3630460 2403252 2436010 3625665
kenneth_jh_han@instance-1:~/Downloads$
```

read1, read2 FASTQ 파일에서 A, C, G, T 염기수를 세어보세요. 결과는 A, C, G, T 순으로 그림과 같이 출력합니다. gzip 파일 상태로 읽기 위해서 import gzip 을 사용해보세요. gzip 사용법을 구글에서 스스로 찾아서 사용밥법을 익혀봅시다.

1) samtools 홈페이지

http://www.htslib.org/download/

에 들어가서 samtools-1.10 으로 된 버튼에서 우클릭 후 주소복사를 합니다.



2) 복사한 주소

https://github.com/samtools/samtools/releases/download/1.10 samtools-1,10,tar,bz2

를 리눅스에서 wget을 사용하여 다운로드 받습니다.

- 3) tar xf 명령어로 압축을 해제합니다.
- 4) 압축을 해제한 디렉터리에 들어가서 ./congifure 라고 입력합니다.

만약 오른쪽 아래 그림같이 gcc... no 라고 뜬다면 c compiler가 없는 것으로 설치해주어야합니다. 4-1 참조.

4-1) sudo apt-get install gcc g++ 을 타이핑 하고 엔터를 눌러 c compiler를 설치해줍니다. 중간에 묻는것이 나오면 y를 눌러서 계속 진행해줍니다.

```
-1:~/Downloads$ wget https://github.com/KennethJHan/Bioinformatics_Programming_101/raw/maste
 -2020-05-21 09:32:52-- https://github.com/KennethJHan/Bioinformatics_Programming_101/raw/master/GATK_BestPractic
 SRR000982.mapped.sorted.markdup.bam
 esolving github.com (github.com)... 140.82.114.4
  nnecting to github.com (github.com) |140.82.114.4|:443... connected.
 TTP request sent, awaiting response... 302 Found
 cation: https://raw.githubusercontent.com/KennethJHan/Bioinformatics_Programming_101/master/GATK_BestPractice/SRR
  2020-05-21 09:32:52-- https://raw.githubusercontent.com/KennethJHan/Bioinformatics Programming 101/master/GATK F
 stPractice/SRR000982.mapped.sorted.markdup.bam
  solving raw.githubusercontent.com (raw.githubusercontent.com)... 151.101.192.133, 151.101.128.133, 151.101.64.133
  necting to raw.githubusercontent.com (raw.githubusercontent.com) | 151.101.192.133 | :443... connected
HTTP request sent, awaiting response... 200 OK
 ength: 23967674 (23M) [application/octet-stream]
aving to: 'SRR000982.mapped.sorted.markdup.bam'
                        -1:~/Downloads$ tar xf samtools-1.10.tar.bz2
                        1:~/Downloads$ cd samtools-1.10/
                bam2depth.c bam mate.c
                                                   bam tview.c
                                                                       configure.ac padding.c
                                                                                                   stats isize.c
                                                                        coverage.c
                bam addrprg.c bam md.c
                                                   bam tview.h
                                                                                      phase.c
                                                                                                    stats isize.h
                                bam plbuf.h
                                                                                                    tmp file.c
                bam cat.c
                                                   bam tview html.c
                                                                       dict.c
                                                                                      sam opts.c
                                                                                                   tmp_file.h
                bam endian.h
                bam fastq.c
                                bam reheader.c
                                                                                      sam_utils.c
                                                                        faidx.c
                bam flags.c
                                                                                      sam view.c
                                                                        htslib-1.10
                bam index.c
                                                   bedidx.h
                                                                                      sample.c
                bam lpileup.c bam sort.c
                                                   config.h.in
                                                                                      sample.h
                                                                                      samtools.h
                bam lpileup.h bam split.c
                                                   config.mk.in
 am2bcf indel.c bam markdup.c bam stat.c
 hecking for gcc... no
checking for cc... no
  nfigure: error: in `/home/kenneth jh han/Downloads/samtools-1.10':
 onfigure: error: no acceptable C compiler found in $PATH
                        -1:~/Downloads/samtools-1.10$
                         1:~/Downloads/samtools-1.10$ sudo apt-get install gcc g++
 eading package lists... Done
 ne following packages were automatically installed and are no longer required:
 se 'sudo apt autoremove' to remove them.
  e following additional packages will be installed:
 binutils binutils-common binutils-x86-64-linux-gnu cpp cpp-7 g++-7 gcc-7 gcc-7-base libasan4 libatomic1
  libbinutils libc-dev-bin libc6-dev libcc1-0 libcilkrts5 libgcc-7-dev libgomp1 libisl19 libitm1 liblsan0 libmpc3
  libmpx2 libquadmath0 libstdc++-7-dev libtsan0 libubsan0 linux-libc-dev manpages-dev
 binutils-doc cpp-doc gcc-7-locales g++-multilib g++-7-multilib gcc-7-doc libstdc++6-7-dbg gcc-multilib make autoconf automake libtool flex bison gdb gcc-doc gcc-7-multilib libgcc1-dbg libgcmp1-dbg libitm1-dbg
  libatomic1-dbg libasan4-dbg liblsan0-dbg libtsan0-dbg libubsan0-dbg libcilkrts5-dbg libmpx2-dbg
 libguadmath0-dbg glibc-doc libstdc++-7-doc
 he following NEW packages will be installed:
 binutils binutils-common binutils-x86-64-linux-gnu cpp cpp-7 g++ g++-7 gcc gcc-7 gcc-7-base libasan4 libatomic1
  libbinutils libc-dev-bin libc6-dev libcc1-0 libcilkrts5 libgcc-7-dev libgomp1 libis119 libitm1 liblsan0 libmpc3
```

libmpx2 libquadmath0 libstdc++-7-dev libtsan0 libubsan0 linux-libc-dev manpages-dev

upgraded, 30 newly installed, 0 to remove and 24 not upgraded. After this operation, 160 MB of additional disk space will be used.

Do you want to continue? [Y/n] y

4-1) which gcc 와 which g++ 가 다음과 같이 나온다면 제대로 설치 된 것입니다.

5) ./configure 를 하였을 때 다음과 같이 FAILED 로 나올 수 있습니다. 이건 뭔가 잘못해서 그런건 아니고, 리눅스에서 프로그램을 설치할 때 필요한 dependency (의존) 프로그램이 없어서 그런것 입니다. 다들 프로그래밍을 해보셔서 잘 아시겠지만 스스로 디버깅 할 수 있는 수준이 되면 프로그래밍이 쉬워집니다. 디버깅을 하는 방법은 오류 메시지를 잘 읽어 보는 것 입니다. 마찬가지로 다음 그림의 노란색 네모친 부분을 보시면 libncurses5-dev 를 설치하라고 나옵니다. (ubuntu 기준)

6) sudo apt-get install libncurses5-dev 를 실행합니다.

```
1:~/Downloads/samtools-1.10$ which gcc
                                                                                                          /usr/bin/acc
                       -1:~/Downloads/samtools-1.10$ which g++
/usr/bin/g++
                    nce-1:~/Downloads/samtools-1.10$
                                                                                                          ------ to
checking for gcc... gcc
checking whether the C compiler works... yes
checking for C compiler default output file name... a.out
checking for suffix of executables...
checking whether we are cross compiling... no
hecking for suffix of object files... o
checking whether we are using the GNU C compiler... yes
checking whether gcc accepts -g... yes
checking for gcc option to accept ISO C89... none needed
checking for grep that handles long lines and -e... /bin/grep
checking for C compiler warning flags... -Wall
checking for special C compiler options needed for large files... no
checking for FILE OFFSET BITS value needed for large files... no
checking location of HTSlib source tree... htslib-1.10
checking for NcursesW wide-character library... no
checking for Neurses library... no
hecking for Curses library... no
configure: error: curses development files not found
The 'samtools tview' command uses the curses text user interface library.
Building samtools with tview requires curses/ncurses/etc development files
to be installed on the build machine; you may need to ensure a package such
as libncurses5-dev (on Debian or Ubuntu Linux) or ncurses-devel (on RPM-based
Linux distributions) is installed.
FAILED. Either configure --without-curses or resolve this error to build
                        1:~/Downloads/samtools-1.10$
                        :~/Downloads/samtools-1.10$ sudo apt-get install libncurses5-dev
                                                                                                          ----- to
Reading package lists... Done
Building dependency tree
Reading state information... Done
The following packages were automatically installed and are no longer required:
grub-pc-bin libnuma1
The following additional packages will be installed:
Suggested packages:
The following NEW packages will be installed:
 libncurses5-dev libtinfo-dev
O upgraded, 2 newly installed, O to remove and 24 not upgraded.
Need to get 256 kB of archives.
After this operation, 1422 kB of additional disk space will be used.
Do you want to continue? [Y/n] y
Get:1 http://us-west1.qce.archive.ubuntu.com/ubuntu bionic-updates/main amd64 libtinfo-dev amd64 6.1-1ubuntu1.18.04
Get:2 http://us-west1.gce.archive.ubuntu.com/ubuntu bionic-updates/main amd64 libncurses5-dev amd64 6.1-1ubuntu1.18
.04 [174 kB]
Fetched 256 kB in 0s (2755 kB/s)
Selecting previously unselected package libtinfo-dev:amd64.
(Reading database ... 70400 files and directories currently installed.)
Preparing to unpack .../libtinfo-dev_6.1-1ubuntu1.18.04 amd64.deb ...
Unpacking libtinfo-dev:amd64 (6.1-1ubuntu1.18.04) ...
Selecting previously unselected package libncurses5-dev:amd64.
Preparing to unpack .../libncurses5-dev 6.1-1ubuntu1.18.04 amd64.deb ...
Unpacking libncurses5-dev:amd64 (6.1-1ubuntu1.18.04) ...
Setting up libtinfo-dev:amd64 (6.1-1ubuntu1.18.04) ...
Setting up libncurses5-dev:amd64 (6.1-1ubuntu1.18.04) ...
Processing triggers for man-db (2.8.3-2ubuntu0.1) ...
```

7) 다시 ./configure 를 입력합니다. 이번에도 FAILED가 나왔는데, 노라색 네모친 부분을 보면 이유가 조금 다릅니다. sudo apt-get install zlib1g-dev 로 dependency를 설치해줍니다.

```
1:~/Downloads/samtools-1.10$ ./configure
checking for gcc... gcc
checking whether the C compiler works... yes
         for C compiler default output file name... a.out
         for suffix of executables...
 hecking whether we are cross compiling... no
 necking for suffix of object files... o
 hecking whether we are using the GNU C compiler... yes
checking whether gcc accepts -g... yes
checking for gcc option to accept ISO C89... none needed
checking for grep that handles long lines and -e... /bin/grep
checking for C compiler warning flags... -Wall
checking for special C compiler options needed for large files... no
checking for FILE OFFSET BITS value needed for large files... no
checking location of HTSlib source tree... htslib-1.10
checking for NcursesW wide-character library... no
checking for Ncurses library... yes
 hecking for working ncurses/curses.h... no
  ecking for working ncurses.h... yes
 hecking for zlib.h... no
 hecking for inflate in -lz... no
 onfigure: error: zlib development files not found
Samtools uses compression routines from the zlib library <a href="http://zlib.net">http://zlib.net</a>.
Building samtools requires zlib development files to be installed on the build
 achine; you may need to ensure a package such as zliblg-dev (on Debian or
Ubuntu Linux) or zlib-devel (on RPM-based Linux distributions) is installed.
FAILED. This error must be resolved in order to build samtools successfully.
        ih han@instance-1:~/Downloads/samtools-1.10$
```

```
1:~/Downloads/samtools-1.10$ sudo apt-get install zlib1g-dev
 eading package lists... Done
 Building dependency tree
 Reading state information... Done
The following packages were automatically installed and are no longer required:
 grub-pc-bin libnuma1
Use 'sudo apt autoremove' to remove them.
The following NEW packages will be installed:
 upgraded, 1 newly installed, 0 to remove and 24 not upgraded.
Need to get 176 kB of archives.
After this operation, 457 kB of additional disk space will be used.
Get:1 http://us-west1.gce.archive.ubuntu.com/ubuntu bionic/main amd64 zlib1g-dev amd64 1:1.2.11.dfsg-Oubuntu2 [176
Fetched 176 kB in 0s (11.1 MB/s)
Selecting previously unselected package zlib1g-dev:amd64.
(Reading database ... 70450 files and directories currently installed.)
Preparing to unpack .../zliblg-dev 1%3a1.2.11.dfsg-Oubuntu2 amd64.deb ...
Unpacking zlib1g-dev:amd64 (1:1.2.11.dfsg-Oubuntu2) ...
Setting up zlib1g-dev:amd64 (1:1.2.11.dfsg-Oubuntu2) ...
Processing triggers for man-db (2.8.3-2ubuntu0.1) ...
   neth jh han@instance-1:~/Downloads/samtools-1.10$
```

8) 다시 ./configure를 입력합니다. 마치 프로그래밍 디버깅 하듯이 오류 메시지를 보고 필요한 dependency 들을 설치해주면 됩니다. 위도우나 맥과 같은 환경에서는 그냥 클릭하면 알아서 잘 설치해주었는데 리눅스에서는 조금은 불편하겠지만, 이렇게 설치해 주어야 합니다. sudo apt-get install libbz2-dev 를 입력합니다.

```
checking for library containing log... -lm
checking for zlib.h... yes
checking for inflate in -lz... yes
 hecking for library containing recv... none required
checking for bzlib.h... no
checking for BZ2 bzBuffToBuffCompress in -lbz2... no
configure: error: libbzip2 development files not found
 he CRAM format may use bzip2 compression, which is implemented in HTSlib
  using compression routines from libbzip2 <a href="http://www.bzip.org/">http://www.bzip.org/>.
 uilding HTSlib requires libbzip2 development files to be installed on the
build machine; you may need to ensure a package such as libbz2-dev (on Debian
or Ubuntu Linux) or bzip2-devel (on RPM-based Linux distributions or Cygwin)
Either confiqure with --disable-bz2 (which will make some CRAM files
produced elsewhere unreadable) or resolve this error to build HTSlib.
configure: error: ./configure failed for htslib-1.10
              @instance-1:~/Downloads/samtools-1.10$
```

```
1:~/Downloads/samtools-1.10$ sudo apt-get install libbz2-dev
Reading package lists... Done
Building dependency tree
Reading state information... Done
The following packages were automatically installed and are no longer required:
 grub-pc-bin libnuma1
Use 'sudo apt autoremove' to remove them.
The following additional packages will be installed:
The following NEW packages will be installed:
 bzip2-doc libbz2-dev
0 upgraded, 2 newly installed, 0 to remove and 24 not upgraded.
Need to get 324 kB of archives.
After this operation, 514 kB of additional disk space will be used.
Do you want to continue? [Y/n] y
Get:1 http://us-west1.gce.archive.ubuntu.com/ubuntu bionic-updates/main amd64 bzip2-doc all 1.0.6-8.1ubuntu0.2 [294
Get:2 http://us-west1.gce.archive.ubuntu.com/ubuntu bionic-updates/main amd64 libbz2-dev amd64 1.0.6-8.1ubuntu0.2
30.0 kB]
Fetched 324 kB in 0s (13.8 MB/s)
Selecting previously unselected package bzip2-doc.
(Reading database ... 70478 files and directories currently installed.)
Preparing to unpack .../bzip2-doc 1.0.6-8.1ubuntu0.2 all.deb ...
 npacking bzip2-doc (1.0.6-8.1ubuntu0.2) ...
Selecting previously unselected package libbz2-dev:amd64.
Preparing to unpack .../libbz2-dev 1.0.6-8.1ubuntu0.2 amd64.deb ...
Unpacking libbz2-dev:amd64 (1.0.6-8.1ubuntu0.2) ...
Setting up libbz2-dev:amd64 (1.0.6-8.1ubuntu0.2) ...
Setting up bzip2-doc (1.0.6-8.1ubuntu0.2) ...
Processing triggers for install-info (6.5.0.dfsg.1-2) ...
                        -1:~/Downloads/samtools-1.10$
```

9) 다시 ./configure를 합니다. 이번에도 에러가 났는데 sudo apt-get install liblzma-dev 로 설치해줍니다.

```
checking for fdatasync... yes
checking for library containing log... -lm
checking for zlib.h... ves
checking for inflate in -lz... yes
checking for library containing recv... none required
checking for bzlib.h... yes
checking for BZ2 bzBuffToBuffCompress in -lbz2... yes
checking for lzma.h... no
checking for 1zma easy buffer encode in -11zma... no
configure: error: liblzma development files not found
The CRAM format may use LZMA2 compression, which is implemented in HTSlib
by using compression routines from liblzma <a href="http://tukaani.org/xz/">http://tukaani.org/xz/>.
Building HTSlib requires liblzma development files to be installed on the
build machine; you may need to ensure a package such as liblzma-dev (on Debian
or Ubuntu Linux), xz-devel (on RPM-based Linux distributions or Cygwin), or
xz (via Homebrew on macOS) is installed; or build XZ Utils from source.
Either configure with --disable-lzma (which will make some CRAM files
produced elsewhere unreadable) or resolve this error to build HTSlib.
configure: error: ./configure failed for htslib-1.10
      h jh han@instance-1:~/Downloads/samtools-1.10$
```

```
1:~/Downloads/samtools-1.10$ sudo apt-get install liblzma-dev
Reading package lists... Done
Building dependency tree
Reading state information... Done
The following packages were automatically installed and are no longer required:
 grub-pc-bin libnuma1
Use 'sudo apt autoremove' to remove them.
Suggested packages:
 liblzma-doc
The following NEW packages will be installed:
 liblzma-dev
0 upgraded, 1 newly installed, 0 to remove and 24 not upgraded.
Need to get 145 kB of archives.
After this operation, 669 kB of additional disk space will be used.
Get:1 http://us-west1.gce.archive.ubuntu.com/ubuntu bionic/main amd64 liblzma-dev amd64 5.2.2-1.3 [145 kB]
Fetched 145 kB in 0s (8586 kB/s)
Selecting previously unselected package liblzma-dev:amd64.
(Reading database ... 70493 files and directories currently installed.)
Preparing to unpack .../liblzma-dev 5.2.2-1.3 amd64.deb ...
Unpacking liblzma-dev:amd64 (5.2.2-1.3) ...
Setting up liblzma-dev:amd64 (5.2.2-1.3) ...
        jh han@instance-1:~/Downloads/samtools-1.10$
```

10) 다시 ./configure를 합니다. 이번엔 제발 되었음 좋겠습니다. 다음 그림 같이 FAIL, error 없이 나온다면 configure가 제대로 된 것 입니다. 만약 다른 dependency가 없어서 오류가 난다면 스스로 필요한 것을 설치하여 해결해봅시다.

11) 지금까지는 설치에 필요한 요소들을 체크하는 과정이었고 이제 정말 설치를 해보겠습니다. 그 전에 which make 를 타이핑 합니다. 오른쪽 그림과 같이 아무 결과가 없다면 make가 없는 것 입니다. which 명령어는 프로그램이 리눅스 PATH 중 어디에 있는지 찾아서 알려주는 명령어입니다. sudo apt-get install make 를 입력합니다. 설치 후 which make를 하였을 때 다음 그림처럼

나오면 제대로 make가 설치된 것 입니다.

```
hecking how to run the C preprocessor... gcc -E
                                                                                                           ..... to -
checking for egrep... /bin/grep -E
checking for ANSI C header files... yes
 hecking for sys/types.h... yes
 hecking for sys/stat.h... yes
 necking for string.h... yes
 hecking for strings.h... yes
checking for inttypes.h... yes
 hecking for stdint.h... yes
hecking for stdlib.h... (cached) yes
checking for unistd.h... (cached) yes
 hecking for sys/param.h... yes
checking for gmtime_r... yes
 ecking for fsync... yes
checking whether fdatasync is declared... yes
checking for fdatasync... yes
 necking for library containing log... -lm
hecking for zlib.h... yes
checking for inflate in -lz... yes
checking for library containing recv... none required
 hecking for BZ2 bzBuffToBuffCompress in -lbz2... yes
 hecking for lzma_easy_buffer_encode in -llzma... yes
hecking for libdeflate.h... no
 necking for libdeflate deflate compress in -ldeflate... no
 hecking for curl easy pause in -lcurl... no
 necking for curl easy init in -lcurl... no
 onfigure: WARNING: libcurl not enabled: library not found
 onfigure: WARNING: GCS support not enabled: requires libcurl support
onfigure: WARNING: S3 support not enabled: requires libcurl support
 necking whether PTHREAD MUTEX RECURSIVE is declared... yes
 onfigure: creating ./config.status
 onfig.status: creating htslib.pc.tmp
                        1:~/Downloads/samtools-1.10$
                         :~/Downloads/samtools-1.10$ which make
```

```
1:~/Downloads/samtools-1.10$
                        1:~/Downloads/samtools-1.10$ sudo apt-get install make
eading package lists... Done
The following packages were automatically installed and are no longer required:
 se 'sudo apt autoremove' to remove them.
The following NEW packages will be installed:
0 upgraded, 1 newly installed, 0 to remove and 24 not upgraded.
After this operation, 381 kB of additional disk space will be used.
Get:1 http://us-west1.gce.archive.ubuntu.com/ubuntu bionic/main amd64 make amd64 4.1-9.1ubuntu1 [154 kB]
Fetched 154 kB in 0s (9749 kB/s)
(Reading database ... 70533 files and directories currently installed.)
Preparing to unpack .../make_4.1-9.1ubuntu1_amd64.deb ...
Unpacking make (4.1-9.1ubuntu1) ...
Setting up make (4.1-9.1ubuntu1) ...
Processing triggers for man-db (2.8.3-2ubuntu0.1) ...
                       -1:~/Downloads/samtools-1.10$
                       -1:~/Downloads/samtools-1.10$ which make
              instance-1:~/Downloads/samtools-1.10$
```

- 11) sudo make 를 타이핑 합니다.
- 12) sudo make install 을 타이핑 합니다.
- 13) which samtools 를 타이핑 합니다.
- 14) samtools 를 실행하였을 때 오른쪽 그림같이 나오면 제대로 된 것 입니다.

```
:~/Downloads/samtools-1.10$ sudo make install
 kdir -p -m 755 /usr/local/bin /usr/local/bin /usr/local/share/man/man1
install -p samtools /usr/local/bin
install -p misc/ace2sam misc/maq2sam-long misc/maq2sam-short misc/md5fa misc/md5sum-lite misc/wgsim /usr/local/bin
install -p misc/blast2sam.pl misc/bowtie2sam.pl misc/export2sam.pl misc/interpolate sam.pl misc/novo2sam.pl misc/pl
ot-bamstats misc/psl2sam.pl misc/sam2vcf.pl misc/samtools.pl misc/seq cache populate.pl misc/soap2sam.pl misc/wgsim
eval.pl misc/zoom2sam.pl /usr/local/bin
install -p -m 644 doc/samtools*.1 misc/wgsim.1 /usr/local/share/man/man1
                       -1:~/Downloads/samtools-1.10$
```

```
:~/Downloads/samtools-1.10$ which samtools
/usr/local/bin/samtools
    th jh han@instance-1:~/Downloads/samtools-1.10$ samtools
Program: samtools (Tools for alignments in the SAM format)
Version: 1.10 (using htslib 1.10)
Usage: samtools <command> [options]
ommands:
 -- Indexina
    dict
                    create a sequence dictionary file
                    index/extract FASTA
    faidx
    faidx
                    index/extract FASTO
    index
                    index alignment

    Editing

                    recalculate MD/NM tags and '=' bases
    calmd
                    fix mate information
    fixmate
    reheader
                    replace BAM header
                    cut fosmid regions (for fosmid pool only)
                   adds or replaces RG tags
                    mark duplicates
  -- File operations
    collate
                   shuffle and group alignments by name
                    concatenate BAMs
                    merge sorted alignments
    merge
                    multi-way pileup
                    sort alignment file
                    splits a file by read group
                    quickly check if SAM/BAM/CRAM file appears intact
    quickcheck
                    converts a BAM to a FASTO
                    converts a BAM to a FASTA
                    read depth per BED region
                    alignment depth and percent coverage
```

# BAM 파일 살펴보기

1) bam 파일을 받았던 경로로 가서, samtools view SRR000982.mapped.sorted.markdup.bam | less -S

를 입력합니다.

를 입력합니다.

2) 오른쪽 아래 그림과 같이 나오게 됩니다.

3) 이번엔 samtools tview SRR000982.mapped.sorted.markdup.bam

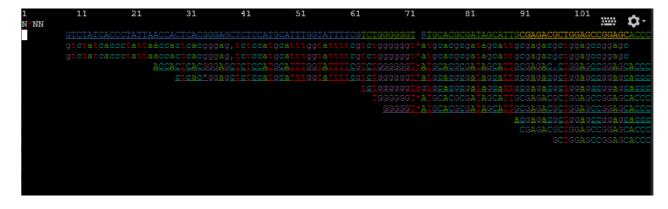
total 49124 4096 May 21 09:39 ./ drwxrwxr-x 3 kenneth jh han kenneth jh han drwxr-xr-x 6 kenneth jh han kenneth jh han 4096 May 21 09:34 ../ rw-rw-r-- 1 kenneth jh han kenneth jh han 173146 May 21 09:33 SRR000982.filtered.variants.annotated.vcfrw-rw-r-- 1 kenneth jh han kenneth jh han 23967674 May 21 09:32 SRR000982.mapped.sorted.markdup.bamrw-rw-r-- 1 kenneth jh han kenneth jh han 3520184 May 21 09:33 SRR000982.mapped.sorted.markdup.bam.bai--rw-rw-r-- 1 kenneth jh han kenneth jh han 8502024 May 21 09:31 -rw-rw-r-- 1 kenneth jh han kenneth jh han 9392196 May 21 09:32 drwxrwxr-x 9 kenneth jh han kenneth jh han 4096 May 21 10:13 samtools-1.10/ -rw-rw-r-- 1 kenneth jh han kenneth jh han 4721173 Dec 6 16:47 han@instance-1:~/Downloads\$ samtools view SRR000982.mapped.sorted.markdup.bam | less -S nneth jh han@instance-1:~/Downloads\$ SRR000982.91192 115 chrM 102M 3326 chrM 60 102M SRR000982.271454 chrM 25 14316 SRR000982.125609 117 chrM 185 chrM 5M1D15M1D6M1D162M 177 RR000982.132204 chrM CGGTTCTGGGGGGTAGTG 3045 SRR000982.159836 chrM 82M25S SRR000982.237678 65 chrM 67 60 113M 13393 13327 SRR000982.469601 chrM SRR000982.124004 131 chrM 3131 RR000982.245083 131 chrM 60 14726

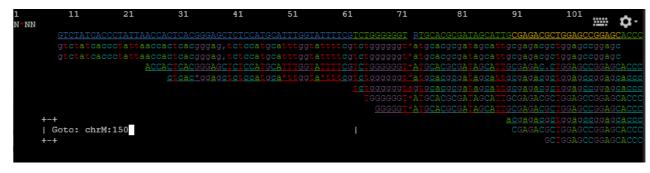
#### BAM 파일 살펴보기

samtools tview 의 모습입니다. c 키를 누르면 염기서열 별로 색을 입혀서 볼 수 있습니다. 방향키로 움직이면 보는 위치를 바꾸면서 볼 수 있습니다.

/ 키를 입력하면 특정 위치로 이동할 수 있는 입력 창이 나옵니다.

chrM:150 을 입력해봅시다.







### BAM 파일 살펴보기

실무에서 bam 파일을 보는 경우가 가끔 있는데, 리드들이 잘 쌓여있는지 기준 서열과 다른 변이들이 잘 있는지 보기 위해 살펴봅니다.



리드라고 하는 것은 시퀀서에서 한 번에 읽은 서열을 의미합니다. 역기서열들이 있으며 기준서열(reference genome)에 붙이면(mapping) 우리가 위에서 본 것 과 같이 나옵니다.

```
##fileDate=20090805
                            ##source=myImputationProgramV3.1
                            ##reference=file:///seq/references/1000GenomesPilot-NCBI36.fasta
                            ##contig=<ID=20,length=62435964,assembly=B36,md5=f126cdf8a6e0c7f379d618ff66beb2da,species="Homo sapiens",taxonomy=x>
Meta-
                            ##INFO=<ID=NS,Number=1,Type=Integer,Description="Number of Samples With Data">
                            ##INFO=<ID=DP,Number=1,Type=Integer,Description="Total Depth">
information
                            ##INFO-<ID-AF, Number-A, Type-Float, Description="Allele Frequency">
                            ##INFO-<ID-AA, Number-1, Type-String, Description-"Ancestral Allele">
                            ##INFO=<ID=DB,Number=0,Type=Flag,Description="dbSNP membership, build 129">
Line
                            ##INFO-<ID-H2, Number=0, Type=Flag, Description="HapMap2 membership">
                            ##FILTER=<ID=q10.Description="Quality below 10">
                            ##FILTER=<ID=s50,Description="Less than 50% of samples have data">
                            ##FORMAT=<ID=GT, Number=1, Type=String, Description="Genotype">
                            ##FORMAT=<ID=GQ, Number=1, Type=Integer, Description="Genotype Quality">
                            ##FORMAT = < ID=DP, Number=1, Type=Integer, Description="Read Depth">
                            ##FORMAT=<ID=HQ, Number=2, Type=Integer, Description="Haplotype Quality">
Header
                                                   REF ALT
                                                                  QUAL FILTER INFO
                                                                                                                         NA00001
                                                                                                                                        NA00002
                                                                                                                                                      NA00003
                                  14370 rs6054257 G
                                                                  29 PASS NS=3;DP=14;AF=0.5;DB;H2
                                                                                                              GT:GQ:DP:HQ 0|0:48:1:51,51 1|0:48:8:51,51 1/1:43:5:..
                                                                  3 q10
                                                                             NS=3;DP=11;AF=0.017
                                                                                                              GT:GQ:DP:HQ 0|0:49:3:58,50 0|1:3:5:65,3 0/0:41:3
Data Line
                                  1110696 rs6040355 A G,T
                                                                 67 PASS
                                                                             NS=2;DP=10;AF=0.333,0.667;AA=T;DB GT:GQ:DP:HQ 1|2:21:6:23,27 2|1:2:0:18,2 2/2:35:4
                                                                  47 PASS
                                                                             NS-3; DP-13; AA-T
                                                                                                              GT:GQ:DP:HQ 0|0:54:7:56,60 0|0:48:4:51,51 0/0:61:2
                                  1234567 microsat1 GTC G,GTCT 50 PASS NS-3;DP-9;AA-G
                                                                                                              GT:GQ:DP 0/1:35:4
                                                                                                                                       0/2:17:2
                                                                                                                                                     1/1:40:3
```

#### FORMAT column

##fileformat=VCFv4.2

tag	meaning
GT	Position에 대한 샘플의 Genotype 0/0 - homozygous reference를 의미 0/1 - heterozygous REF/ALT를 의미 1/1 - homozygous ALT를 의미
AD	Allele Depth
DP	Depth

VCF 파일은 기준서열과 다른 변이들을 테이블 형식으로 표현한 파일입니다.

샾 기호(#) 두 개인 ## 에는 VCF 파일을 생성할 때 사용한 옵션 등의 설명이 있고

한 개인 # 에는 각 컬럼의 타이틀이 붙어있습니다.

9개의 의무적 컬럼이 있고 10번째 부터는 샘플의 FORMAT에 해당 값이 있습니다.

#### 변이라고 하는 것은 기준서열과 일치하지 않는 염기를 의미합니다.

SNP (Single Nucleotide Polymorphism)

: 기준서열과 비교하여 하나의 서열이 바뀐것을 의미

기준 서열 ACAAGGTT

Read **ACATGGTT** 

Insertion

: 기준서열과 비교하여 서열이 추가된 것을 의미

기준 서열 ACAA-GGTT

ACAATGGTT Read

Deletion

: 기준서열과 비교하여 서열이 제거된 것을 의미

기준 서열 ACAAGGTT

ACA\*GGTT Read

AD (Allele Depth)는 GT (Genotype)를 기준으로 표현하는데,

CHROM	POS	REF	ALT	FORMAT	SAMPLE
chr20	1234	А	Т	GT:AD:DP	0/1:23,11:34

Variant caller 중 하나인 GATK 를 기준으로 설명하자면 AD 에서 첫 번째는 GT의 0, 두 번째는 GT의 1, 세번째는 GT의 2 번째 를 의미합니다.

예를 들어 chr20:1234 A → T 에서, A는 GT의 0, T는 GT의 1입니다. AD는 23,11 로 써져있는데 순서대로 0인 A가 → 23, 1인 T가 → 11 만큼의 depth를 나타냅니다.

CHROM	POS	REF	ALT	FORMAT	SAMPLE
chr1	1234	A	Т	GT:AD:DP	0/1:23,11:34
chr3	2222	TC	T,TCC	GT:AD:DP	1/2:2,31,21:54
chr21	2830	Т	G	GT:AD:DP	1/1:0,44:44

Chr1: 1234 위치의 쌓인 ReadDepth는 34다. (O/X)

Chr1:1234 에서 A의 개수는 23개 T의 개수는 11개다. (O/X)

Chr3:2222 위치의 변이 종류는 SNP, Insertion, Deletion이다. (O/X)

Chr3:2222 위치의 REF Depth는 31, ALT Depth는 21이다. (O/X)

정답은 다음 슬라이드에

CHROM	POS	REF	ALT	FORMAT	SAMPLE
chr1	1234	A	Т	GT:AD:DP	0/1:23,11:34
chr3	2222	TC	T,TCC	GT:AD:DP	1/2:2,31,21:54
chr21	2830	Т	G	GT:AD:DP	1/1:0,44:44

Chr1: 1234 위치의 쌓인 ReadDepth는 34다. (O)

Chr1:1234 에서 A의 개수는 23개 T의 개수는 11개다. (O)

Chr3:2222 위치의 변이 종류는 SNP, Insertion, Deletion이다. (X) Insertion (TC  $\rightarrow$  TCC) 과 Deletion (TC  $\rightarrow$  T) 만 있고 SNP는 없다.

Chr3:2222 위치의 REF Depth는 31, ALT Depth는 21이다. (X) GT에서 TC:0, T:1, TCC:2 로 볼 수 있는데, AD에서 2,31,21 에서 TC,T,TCC 의 순서로 일치하기에 REF 인 TC는 2, ALT1인 T는 31, ALT2인 TCC는 21이다.

```
enneth jh_han@instance-1:~/Downloads$ python3 calc_snp_indel.py SRR000982.filtered.variants.annotated.vcf
364 10 24
 enneth jh han@instance-1:~/Downloads$
```

VCF 파일에서 SNP, Insertion, Deletion 의 숫자를 세어보세요. ALT 컬럼에서 쉼표로 구분되어 alt가 여러개 있는 경우도 있으니 이 점 참고하여 진행해주세요.

답은 그림과 같이 나옵니다.

#### 마무리

오늘은 FASTQ, BAM, VCF 파일을 살펴보고 리눅스 툴을 설치해보았습니다.

과제를 꼭 수행해보시기 바랍니다.

그럼 다음에 또 만나요.